Modelización del Riesgo Operacional

Cristhian Rodriguez

Riesgo Operacional

Nuestra Hoja de Ruta

Al final de esta sesión, serán capaces de:

1. **Identificar** las fuentes y categorías del Riesgo Operacional en un entorno financiero.
2. **Justificar** por qué los datos de OpRisk son un desafío único (Baja Frecuencia, Alta Severidad).
3. **Describir** la lógica del Enfoque de Distribución de Pérdidas (LDA) como solución a este desafío.
4. **Implementar** un modelo LDA básico, modelando Frecuencia (Poisson) y Severidad (LogNormal) por separado.
5. **Construir** la distribución de pérdida agregada usando Simulación de Monte Carlo.
6. **Calcular** el capital regulatorio (OpVaR) a partir de la distribución simulada.

Una Historia Real de 4.900 Millones de Euros

Jérôme Kerviel, trader de Société Générale.

La Anatomía del Desastre (2008)

- **Persona (Fraude):** Kerviel realizó operaciones no autorizadas masivas (apostando 50.000M€, más que el valor del banco).
- **Proceso (Fallo de Control):** Usó su conocimiento de los sistemas de back-office para ocultar sus operaciones y saltarse los límites de riesgo.
- **Sistema (Fallo de Alerta):** Los sistemas generaron alertas, pero fueron ignoradas o malinterpretadas como errores.

El Resultado

Pérdida neta para el banco: **4.9 mil millones de euros**. Uno de los mayores fraudes de la historia.

La Pregunta del Billón de Dólares

¿Cómo puede un banco prepararse para un evento que nunca le ha ocurrido, pero que podría quebrarlo? Este caso será nuestra guía para entender el modelado de OpRisk.

¿Qué puede salir mal en nuestro día a día como Quants?

CEU

Escenario: Somos el equipo Quant de *Banco CEU*

Tenemos modelos de VaR en Python/R, traders, y sistemas de back-office. Identifiquemos 1-2 ejemplos para cada categoría (Basilea):

- **Fraude Interno (Personas):** Un quant frustrado se lleva los modelos a la competencia. *(Como Kerviel, pero con propiedad intelectual)*.
- **Errores Humanos (Personas):** Un analista usa datos de `test` en lugar de `producción` para el VaR del día.
- **Fallo de Procesos:** El trader ejecuta la orden, pero el back-office se olvida de confirmarla.
- **Fallo de Sistemas:** El servidor donde corre el script de Python del CVA se cae y no hay `backup`.
- **Eventos Externos:** Un ataque de Ransomware encripta nuestros servidores.

El Problema Fundamental del Quant

CEU

Riesgo de Mercado

- **Frecuencia:** Alta (datos diarios).
- **Severidad:** Generalmente baja.
- **Resultado:** Muchos datos, colas *delgadas*.

Riesgo Operacional

- **Frecuencia:** Muy Baja.
- **Severidad:** Extremadamente Alta.
- **Resultado:** Pocos datos, colas muy gordas.

El Desafío (LFHS: Low Frequency, High Severity)

¿Cómo modelamos la probabilidad de un evento como el de Kerviel, que **nunca ha ocurrido** en nuestro banco, pero que sabemos que **podría** ocurrir y quebrarnos?
No podemos usar el pasado para predecir eventos que solo ocurren una vez.

Construyendo el Mosaico de Datos

Dado que una sola fuente no es suficiente, el regulador (Basilea II) exige combinar 4 elementos para el *Advanced Measurement Approach* (AMA):

1. **Datos de Pérdidas Internas (ILD)**
   - *Qué es:* Base de datos de *todas* las pérdidas operacionales sufridas por el banco.
   - *Pro:* Datos 100 % relevantes. Útil para eventos de alta frecuencia y baja severidad.
   - *Con:* No contiene un Kerviel. Inútil para la cola de la distribución.
2. **Datos de Pérdidas Externas (ED)**
   - *Qué es:* Bases de datos de consorcios (ej. ORX) con pérdidas de *otros* bancos.
   - *Pro:* Sí contiene el Kerviel de SocGen y otros desastres. Es nuestra única fuente de datos para la cola.
   - *Con:* ¿Es relevante para nosotros? Requiere `scaling` (escalado).
3. **Análisis de Escenarios (SCA)**
   - *Qué es:* Workshops con expertos para imaginar lo peor. *¿Y si un Kerviel nos pasara a nosotros? ¿Cuál sería el impacto?*.
   - *Pro:* Es `Forward-looking`. Captura riesgos emergentes.
   - *Con:* Altamente subjetivo.
4. **Indicadores Clave de Riesgo (KRIs)**
   - *Qué es:* Métricas que miden la *presión* sobre el sistema (ej. % de rotación de personal, Nº de logins fallidos).
   - *Pro:* Monitoreo en tiempo real.
   - *Con:* Difícil de vincular a una pérdida en euros.

El Objetivo es Siempre el Mismo

CEU

Recordatorio de Módulos Anteriores

- **Riesgo de Mercado:** Calculamos el VaR sobre una distribución de P&L de la cartera.
- **Riesgo de Crédito:** Calculamos el VaR sobre una distribución de pérdidas de la cartera (CreditMetrics).

El Objetivo Final en Gestión de Riesgos

Encontrar una distribución de pérdidas y calcular un cuantil alto (VaR / ES).

El Desafío del OpRisk

¿Cómo **construimos la distribución de pérdidas** a partir de las 4 fuentes de datos que acabamos de ver?

La respuesta: LDA

Desacoplando el Problema (¡La idea clave!)

No modelamos la pérdida agregada anual L directamente. En lugar de eso, definimos L como una **suma aleatoria** o **proceso compuesto**:

$$L = \sum_{i=1}^{N} S_i$$

Donde:

- N es el **número de eventos** de pérdida en un año (Frecuencia).
- S_i es la **severidad** (impacto en euros) de cada evento i.

El Plan de Ataque Quant: Divide y Vencerás

1. **Paso 1:** Ajustar una distribución a la **Frecuencia** N (usando datos internos).
2. **Paso 2:** Ajustar una distribución de cola gorda a la **Severidad** S (usando datos internos, externos y escenarios).
3. **Paso 3:** Combinarlos con Monte Carlo para obtener la distribución de L.

Construyendo Intuición para el Proceso Compuesto

Imaginemos que queremos estimar el daño total por meteoritos en la Tierra en un año (L).

Frecuencia (N)

- ¿Cuántos meteoritos impactan al año?
- Podemos estimarlo con datos históricos de impactos.
- $N \sim \text{Poisson}(\lambda_{\text{meteoritos}})$

Severidad (S)

- ¿Qué tamaño/daño causa cada meteorito?
- La mayoría son pequeños (grava), pero uno podría ser el que extinguió a los dinosaurios (cola gorda).
- $S \sim \text{LogNormal}(\mu, \sigma)$

Pérdida Agregada (L)

El daño total $L = \sum_{i=1}^{N} S_i$ es la suma del daño de un número aleatorio de impactos de tamaño aleatorio. No podemos saberlo a priori, debemos simularlo.

¿Cuántas veces ocurre?

CEU

Candidato Principal: Distribución de Poisson

- Asume que los eventos son **independientes** y ocurren a una tasa constante λ.
- $P(N = k) = \frac{e^{-\lambda}\lambda^k}{k!}$
- *Ajuste:* $\hat{\lambda}$ es simplemente el número promedio de eventos por año en nuestros datos internos.
- *Ejemplo:* Si en 10 años hemos tenido 80 eventos de *Fallo de Sistema*, $\hat{\lambda} = 8$ eventos/año.

Matiz: ¿Qué pasa si hay Contagio? (Sobredispersión)

El supuesto de independencia de Poisson puede fallar.

- **Ejemplo de Contagio:** Un ciberataque exitoso (evento 1) revela una vulnerabilidad, lo que desencadena cientos de ataques de imitación (eventos 2, 3, ...).
- **Consecuencia:** La varianza de los eventos es mayor que la media ($Var(N) > E[N]$).
- **Solución:** Usamos la **Binomial Negativa**, que tiene un parámetro extra para modelar esta *sobredispersión*.

Actividad Interactiva

Somos el *Banco CEU*. En 10 años, hemos registrado 5 pérdidas en la categoría *Fraude de Trading*:

[1.5M€, 0.8M€, 2.0M€, 1.1M€, 3.5M€]

Pregunta a la Clase (¡Apuesten!)

Basado **únicamente** en estos datos, ¿cuánto estimarían que es el capital necesario para sobrevivir al *peor año en 1000*? (OpVaR 99.9 %)

(a) ˜5 M€ (b) ˜10 M€ (c) ˜50 M€

La Realidad (Dato Externo)

Pérdida de Kerviel (SocGen): **4,900 M€**

Nuestros datos internos no contienen la información necesaria para estimar el riesgo de cola.

¿Cuánto duele cada vez?

Buscamos una distribución continua, positiva ($S > 0$) y de **cola gorda**.

Contra-ejemplo: ¿Por qué NO usar una Normal?

- Permite pérdidas negativas (no tiene sentido).
- Sus colas son *demasiado delgadas*. Subestimaría masivamente la probabilidad de un Kerviel.

Candidatos Comunes (Nivel FRM)

- **Log-Normal:** El *caballo de batalla*. Si los shocks son multiplicativos, el resultado es Log-Normal. Naturalmente positiva y con cola derecha gorda.
- **Weibull:** Flexible, usada también en ingeniería de fiabilidad.
- **Pareto / GPD (Teoría de Valor Extremo - EVT):** El mejor modelo para la *cola extrema*. ¡La misma GPD que usamos para el VaR de Mercado!

Combinando lo Mejor de Dos Mundos

CEU

El Cuerpo (Body)

- **Datos:** Pérdidas *pequeñas* y frecuentes (¡ 1M€).
- **Fuente:** Datos Internos (ILD).
- **Modelo:** Se ajusta una **Log-Normal**.

La Cola (Tail)

- **Datos:** Pérdidas *grandes* y raras (¿ 1M€).
- **Fuente:** Datos Externos (Kerviel) y Análisis de Escenarios.
- **Modelo:** Se ajusta una **Pareto (GPD)**.

Intuición

Usamos nuestros datos para lo que son buenos (el día a día) y los datos de desastres de otros para lo que no podemos ver (la catástrofe).

Juntando Frecuencia y Severidad

Tenemos:

- $N \sim$ Poisson(λ)
- $S \sim$ Body-Tail (LogNormal + GPD)

Queremos la distribución de la pérdida agregada: $L = \sum_{i=1}^{N} S_i$

El Desafío Matemático

La distribución de L (un Proceso Compuesto) **no tiene una forma analítica cerrada**. No podemos escribir $f_L(x) = \ldots$ y calcular su cuantil (VaR) directamente.

Pregunta

Conocemos la distribución de las piezas (N y S), pero no de la suma... ¿Qué herramienta usamos siempre en estos casos?
(Pista: La usamos en la Semana 9 para el CVA). **Simulación de Monte Carlo**

El Algoritmo de Simulación (¡Para Quants!)

Queremos construir el histograma (la PDF empírica) de L.

1. **Inicializar:** Crear un vector vacío `perdidas_anuales`.
2. **Bucle (simular 1M de años):**
   1. **Simular Frecuencia:** Generar un número de eventos para este año: $n \sim \text{Poisson}(\lambda)$.
   2. **Simular Severidad:** Si $n > 0$, generar n pérdidas desde el modelo de severidad: $s_1, \ldots, s_n \sim$ LogNormal/GPD.
   3. **Agregar:** Calcular la pérdida total del año: $L_{\text{año}} = \sum_{i=1}^{n} s_i$.
   4. **Almacenar:** Añadir $L_{\text{año}}$ al vector `perdidas_anuales`.
3. **Fin del Bucle.**

Resultado

El vector `perdidas_anuales` es la distribución de pérdidas que buscábamos.

Cálculo del VaR Operacional (OpVaR)

El vector `perdidas_anuales` (con 1M de puntos) *es* nuestra distribución de pérdidas.

El Capital Regulatorio (Basilea)

El capital para Riesgo Operacional se define como el **VaR** de esta distribución con un nivel de confianza del **99.9 %** y un horizonte de 1 año.

$$OpVaR_{99,9\,\%} = \text{Percentil}(\texttt{perdidas_anuales}, 99{,}9)$$

Intuición Financiera

El $OpVaR_{99,9\,\%}$ es el capital necesario para sobrevivir al *peor año en 1000 años*. Si el resultado es 500M€, el banco debe tener ese capital listo solo para cubrir el riesgo de que sus propios sistemas, personas o procesos fallen.

¿Cómo se suma el capital de las 7 líneas?

Hemos calculado el OpVaR para *Fraude Interno*. Pero un banco tiene 7 categorías de riesgo operacional (fraude ext., fallos de sistema, etc.).

El Error Fatal

El OpVaR total del banco **NO ES** la suma de los VaR individuales.

$$VaR_{\text{Total}} \neq VaR_{\text{Fraude}} + VaR_{\text{Sistemas}} + \dots$$

(Recordatorio: El VaR no es subaditivo. Sumarlos implicaría correlación perfecta).

La Solución Elegante: Cópulas

Para agregar riesgos que no son perfectamente dependientes, usamos **Cópulas**.
Intuición: Una cópula es un *mapa de dependencia* que nos dice cómo se mueven juntas las probabilidades de diferentes riesgos. Permite capturar que, en una crisis, el fraude y los fallos de proceso aumentan *juntos* (dependencia en la cola).

Juntando Todo el Puzzle

CEU

Setup:

- Para cada categoría $k \in \{1, \ldots, 7\}$, tenemos un modelo de Frecuencia $N_k \sim$ Poisson(λ_k) y Severidad S_k.
- Tenemos una matriz de correlación (ej. de una Cópula t-Student) para las frecuencias.

Algoritmo de Simulación (1M de años):

1. **Simular Dependencia:** Generar 7 números aleatorios correlacionados $(u_1, \ldots, u_7)$ desde la Cópula.
2. **Simular Frecuencias Correlacionadas:**
   - Para cada categoría k, transformar u_k en un número de eventos: $n_k = F^{-1}_{\text{Poisson}(\lambda_k)}(u_k)$.
3. **Simular Severidades (Independientes):**
   - Para cada categoría k, si $n_k > 0$, generar n_k pérdidas $s_{k,1}, \ldots, s_{k,n_k}$.
4. **Agregar Pérdida Total del Año:** $L_{\text{año}} = \sum_{k=1}^{7} \sum_{i=1}^{n_k} s_{k,i}$.
5. **Almacenar** $L_{\text{año}}$.

Conclusión

El OpVaR total se calcula como el percentil 99.9 % de la distribución de $L_{\text{año}}$ final. Este enfoque captura los beneficios de la diversificación entre tipos de riesgo.

Resumen

Conceptos Clave Asimilados Hoy

- El Riesgo Operacional es el riesgo de **fallo**, anclado en 4 categorías (Personas, Procesos, Sistemas, Eventos Ext.).
- Los datos son de **Baja Frecuencia y Alta Severidad** (LFHS), lo que obliga a usar fuentes externas y escenarios.
- El modelo estándar (LDA) desacopla el problema en **Frecuencia (N)** y **Severidad (S)**.
- La agregación $L = \sum S_i$ requiere **Monte Carlo**.
- El capital es el $OpVaR_{99,9\,\%}$ de la distribución L simulada.
- La agregación entre categorías de riesgo requiere **Cópulas** para modelar la dependencia.

Taller Práctico en Python/R

Objetivo: Implementar el algoritmo LDA-Monte Carlo para calcular el OpVaR.

Escenario: *Banco Quant*

El dpto. de OpRisk ha determinado los siguientes parámetros para el riesgo de *Ciberataques*:

- **Frecuencia (N):** Sigue una Poisson$(\lambda = 4)$.
- **Severidad (S):** Sigue una LogNormal$(\mu = 15, \sigma = 2{,}5)$.

Entregables (Notebook)

1. **Simulación:** Realizar una simulación de Monte Carlo con $1,000,000$ de años para $L = \sum_{i=1}^{N} S_i$.
2. **Visualización:** Graficar el histograma de la distribución de pérdida agregada L. (Pista: usen un `log scale` en el eje Y para ver la cola!).
3. **Cálculo de Riesgo:** Calcular la Pérdida Esperada $E[L]$, el $OpVaR_{99,9\,\%}$ y el $ES_{99,9\,\%}$.
4. **Análisis de Sensibilidad:** Repetir el cálculo 3, pero cambiando σ a $2{,}0$ y a $3{,}0$. Escribir una conclusión (1 párrafo) sobre el impacto de la *gordura* de la cola de severidad en el capital.

En Python, esto es `numpy.random.poisson(lam=4)` y `numpy.random.lognormal(mean=15, sigma=2.5)`

Gracias. ¿Preguntas?

Cristhian Rodriguez